

++추가 자료

알고리즘	동일한 변수조합	3-Fold 평균 PR-AUC
XGBoost	Model 44	0.974221
LightGBM	조합 3 = Model 44	0.973372

Fold	XGBoost	LightGBM	우세
1	0.972156	0.968004	XGB
2	0.973471	0.976293	LGBM
3	0.977035	0.975818	XGB

동일한 Model 44 변수조합과 3-Fold Expanding Window 기준으로 비교하면 XGBoost의 평균 PR-AUC가 0.974221로 LightGBM(0.973372)보다 0.000849 높다.
따라서 현재 CV 기준에서는 XGBoost가 근소하게 우세하다

++추가설명(기존내용과 거의 동일함)

XGBoost vs LightGBM 선정 기준

- **동일한 시간교차검증 기준으로 평균 PR-AUC 비교**
 - 평균 PR-AUC를 **1순위 선정 기준**으로 사용.
 - 평균 PR-AUC 차이가 명확하면 높은 모델을 우선 선정.
 - **PR-AUC가 비슷한 경우**
 - Fold별 **PR-AUC 표준편차와 후반 Fold 성능**을 비교하여 시간적 안정성을 확인.
 - 필요 시 동일 Recall에서 Precision/FP를 비교.
 - **과적합 및 시간적 안정성 확인**
 - Time CV 결과를 통해 후반 Fold에서 성능이 급격히 하락하는지 확인.
 - Train-Validation 성능 차이와 Best Iteration도 함께 확인.
 - **성능이 사실상 동일한 경우**
 - 학습 시간, 추론 시간, 메모리 등 **효율성과 재현성**을 기준으로 최종 선택.
- 최종 순서: 평균 PR-AUC → 시간적 안정성 → 동일 Recall에서 Precision/FP → 과적합 여부 → 효율성

++과적합 판별법(상세)

2. 그런데 "과적합"을 더 직접적으로 보려면

Train 성능 vs Validation 성능을 봐야 해.

예를 들어:

	Train PR-AUC	Validation PR-AUC
모델 A	0.999	0.969
모델 B	0.975	0.968

A는 Train에서는 거의 완벽한데 Validation에서 떨어지니까 **과적합 가능성이 더 높다고** 볼 수 있어.

즉,

Time CV = 미래 데이터에 대한 일반화가 안정적인가?

Train-Validation gap = 학습 데이터에 과도하게 맞춰졌는가?



+추가 자료

통합 OOF는 언제 쓰냐?

나중에 최종 모델의 전체 cv 예측을 하나로 모아서

- 전체 OOF PR-AUC
- 전체 OOF F1
- 하나의 최종 threshold

같은 걸 보고 싶을 때 유용해.

특히 **threshold**를 정할 때는 전체 OOF 예측을 활용해서 하나의 threshold를 정하는 방식이 꽤 깔끔해.

하지만 지금 모델 알고리즘 선택 단계에서 반드시 추가해야 하는 필수 절차는 아니야.

