


++다음시간에 해야할 것++

1. 상관분석 > 두 변수 중 다 유의미한 변수선택
2. VIF계수 > 10이상이어도 유의미한 변수는 제거 X
3. 같이 변수 정해야 함
4. 변수 정하면 VIF 계수를 다시 확인해봐야 함



상관계수	해석
0.00~0.30	거의 없음
0.30~0.50	약한 상관
0.50~0.70	보통
0.70~0.90	높음
0.90 이상	매우 높음(중복 변수 의심)

	Variable1	Variable2	Correlation
15	amt	amt_ratio_to_mean	0.974531
46	time_diff_sec	time_diff_hr	0.974101
27	move_distance_km	merchant_shift_km	0.965826
200	amt_ratio_to_mean	amt_zscore_card	0.901942
16	amt	amt_zscore_card	0.881250
207	customer_transaction_count	customer_category_count	0.758405
181	hour	night_transaction	0.748164

>> 여기 변수들을 상관계수가 **0.7**이상이므로, 상관관계가 높은 두 변수 중에 한 개를 선택해야함

>> 분석, 모델링, 이성거래 탐지, 가설검정에 우선적으로 유의한 변수 선택

VIF계수

	Variable	VIF
1	move_distance_km	77.988217
9	merchant_shift_km	77.987561
16	amt_ratio_to_mean	36.016295
0	amt	31.797664
10	time_diff_hr	29.095276
2	time_diff_sec	29.058063
18	customer_transaction_count	21.443703
14	customer_mean_amt	17.104166
4	count_30min	14.154260

19	customer_category_count	12.973792
12	hour	10.599571

>> VIF 계수가 10이상이므로, 제거 대상 변수임

>> 하지만, 10이상이어도 무조건 제거 하지는 않음

>> 도메인(이상거래탐지)에 중요한 변수는 제거하지 않는다

>> 제거대상:

두 변수가 비슷한 정보를 가진 경우

의미가 거의 같은 변수

공식으로 만들어진 변수

상관계수 + VIF 가 동시에 높은 위험변수

** 참고 **

변수	VIF	판단	추천
move_distance_km	77.99	⚠ 매우 높음	merchant_shift_km와 중복 여부 확인 후 하나 선택
merchant_shift_km	77.99	⚠ 매우 높음	위와 동일
amt_ratio_to_mean	36.02	⚠ 높음	amt, customer_mean_amt와 수식으로 연결됨
amt	31.80	⚠ 높음	핵심 변수라 유지 추천
time_diff_hr	29.10	⚠ 높음	time_diff_sec와 거의 같은 정보
time_diff_sec	29.06	⚠ 높음	둘 중 하나만 사용 추천
customer_transaction_count	21.44	주의	유지 가능
customer_mean_amt	17.10	주의	유지 가능
count_30min	14.15	주의	유지 추천(가설 핵심 변수)
customer_category_count	12.97	주의	유지 가능
hour	10.60	경계	유지 가능
distance_km_2	8.37	양호	유지

amt_zscore_card	4.75	좋음	유지
customer_std_amt	4.61	좋음	유지
recent_24h_txn_count	4.22	좋음	유지
나머지	<3	매우 좋음	유지